



گزارش مفهومی و تحلیلی آکادمی همراه اول
کاربرد هوش مصنوعی در مدیریت ترافیک و پیش بینی قطعی شبکه

وحید حمزه

۱۸ خرداد ۱۴۰۵

فهرست مطالب

۳	چکیده مدیریتی
۳	۱ مقدمه
۳	۲ مفهوم Big Data در شبکه‌های مخابراتی
۴	۱.۲ منابع و انواع داده‌ها در شبکه‌های مخابراتی
۴	۱.۱.۲ داده‌های ترافیک و شبکه و مدل‌سازی ریاضی آن
۴	۲.۱.۲ داده‌های تجهیزات، زیرساخت و مشتریان
۵	۲.۲ بهینه‌سازی و مدیریت هوشمند شبکه (Network Optimization)
۵	۱.۲.۲ تخصیص پویای منابع (Dynamic Resource Allocation)
۵	۲.۲.۲ نگهداری پیش‌گیرانه و تشخیص آنومالی (Predictive Maintenance)
۶	۳.۲ پیاده‌سازی کلان‌داده در اپراتورهای پیشرو و داخلی
۷	۳ کاربرد یادگیری ماشین در مدیریت ترافیک و پیش‌بینی قطعی
۷	۱.۳ تحلیل الگوهای ترافیکی و پیش‌بینی بار شبکه
۸	۲.۳ مدیریت ترافیک در شرایط و رخداد‌های خاص
۸	۳.۳ شناسایی نقاط مستعد اختلال و پیش‌بینی قطعی
۹	۴.۳ بازتوزیع هوشمند منابع بر اساس تحلیل داده‌ها
۹	۵.۳ پیاده‌سازی عملی: تشخیص ناهنجاری با تلفیق تجزیه STL و جنگل انزوا
۱۱	۴ همسویی استراتژیک با چشم‌انداز تحقیق و توسعه همراه اول (MCI R&D)
۱۱	۱.۴ شاخص‌های کلیدی عملکرد (KPI) در نگهداری پیش‌گیرانه
۱۲	۵ جمع‌بندی و نتیجه‌گیری راهبردی
۱۳	۶ مراجع
۱۵	پیوست آ: کدهای منبع تشخیص ناهنجاری ترافیک شبکه

چکیده مدیریتی

این سند راهبردی، چارچوبی جامع برای گذار معماری مدیریت ترافیک اپراتورهای ارتباطی از سیستم‌های واکنشی سنتی به شبکه‌های پیش‌گیرانه و خودمختار (Zero-Touch Networks) ارائه می‌دهد. با تلفیق زیرساخت‌های کلان‌داده، مدل‌های پیشرفته یادگیری ماشین (از جمله شبکه‌های گرافی DCRNN و الگوریتم‌های LSHiForest) و معماری یادگیری فدرال در بستر استاندارد NWDAF، این وایت‌پیپر نشان می‌دهد که چگونه اپراتورها می‌توانند با تحلیل بلادرنگ داده‌های CDR و KPI‌های لایه دسترسی رادیویی (RAN)، شاخص‌های کلیدی عملکرد (MTTR و OEE) را بهینه‌سازی کرده و پایداری شبکه را در شرایط بحرانی تضمین نمایند.

۱ مقدمه

شبکه‌های مخابراتی امروزی حجم بسیار زیادی از داده‌های کاربران، ترافیک شبکه و وضعیت تجهیزات را تولید می‌کنند. اپراتورهای بزرگ مخابراتی با تحلیل این داده‌ها تلاش می‌کنند عملکرد شبکه را بهبود داده و از بروز اختلال یا ازدحام جلوگیری کنند. در سال‌های اخیر، استفاده از الگوریتم‌های یادگیری ماشین به یکی از روندهای مهم در مدیریت هوشمند شبکه تبدیل شده است. این الگوریتم‌ها می‌توانند با بررسی داده‌های گذشته، الگوهای ترافیکی را شناسایی کرده و زمان‌های پرتراфик یا نقاط مستعد اختلال را پیش‌بینی کنند. هدف این پروژه، آشنایی با کاربرد مفاهیم هوش مصنوعی و تحلیل داده در شبکه‌های مخابراتی و بررسی نقش آن‌ها در مدیریت ترافیک و پیش‌بینی قطعی شبکه است.



شکل ۱: چارچوب پیشنهادی مدیریت هوشمند شبکه

۲ مفهوم Big Data در شبکه‌های مخابراتی

مبحث «بیگ دیتا» (کلان‌داده) در شبکه‌های مخابراتی یکی از جذاب‌ترین و کاربردی‌ترین حوزه‌های تلاقی مهندسی مخابرات، فناوری اطلاعات و علوم داده است. صنعت مخابرات به صورت روزانه حجم عظیمی از داده‌های ناهمگون را تولید می‌کند. هر تماسی که برقرار می‌شود، هر پیامکی که ارسال می‌گردد، هر اتصال که به شبکه اینترنت برقرار می‌شود، جابجایی کاربر بین دکل‌های مخابراتی (Handover) و حتی لاگ‌های خطای تولیدشده توسط تجهیزات سخت‌افزاری، همگی به عنوان منابع تولید داده شناخته می‌شوند.

کلان‌داده در این حوزه به معنای جمع‌آوری، ذخیره‌سازی، پردازش و استخراج الگوهای معنادار از این اقیانوس اطلاعات در زمان واقعی (Real-time) یا نزدیک به واقعی است. یکی از مهم‌ترین و غنی‌ترین منابع داده در این

شبکه‌ها، رکوردهای جزئیات تماس یا CDR (Call Detail Record) است. تحلیل داده‌های ترافیکی CDR به اپراتورها کمک می‌کند تا الگوهای مصرف شبکه را به دقت رصد کرده و گلوگاه‌های ترافیکی را پیش از وقوع بحران شناسایی کنند. در ادامه به بررسی سرفصل‌های مهم این موضوع می‌پردازیم:

۱.۲ منابع و انواع داده‌ها در شبکه‌های مخابراتی

برای پیاده‌سازی هرگونه الگوریتم هوشمند، ابتدا باید شناخت دقیقی از ساختار، ابعاد و مدل ریاضی داده‌هایی که در لایه‌های مختلف شبکه جریان دارند، پیدا کرد. داده‌های مخابراتی به دلیل گستردگی زیرساخت، تنوع بالایی از ساختارهای متنی، سری‌های زمانی و سیگنال‌های نویزی را شامل می‌شوند.

۱.۱.۲ داده‌های ترافیک و شبکه و مدل‌سازی ریاضی آن

این داده‌ها شامل لاگ‌های CDR (شامل زمان شروع تماس، شناسه مبدأ و مقصد، مدت زمان اتصال و نوع سرویس) و داده‌های مربوط به پهنای باند مصرفی در سطح سلول هستند. از دیدگاه مهندسی ترافیک مخابرات، ورود بسته‌ها یا درخواست‌های تماس به شبکه را می‌توان به صورت یک فرآیند نقطه‌ای پواسون غیرهمگن (Non-Homogeneous Poisson Point Process) مدل‌سازی کرد تا نوسانات ترافیک در ساعات مختلف شبانه‌روز لحاظ شود [۳]. اگر $\lambda(t)$ نرخ متوسط و متغیر با زمان ورود درخواست‌ها (تعداد درخواست در ثانیه) باشد، احتمال ورود دقیقاً k درخواست در بازه زمانی $[t_1, t_2]$ برابر است با:

$$P(N(t_2) - N(t_1) = k) = \frac{\left(\int_{t_1}^{t_2} \lambda(t) dt \right)^k e^{-\int_{t_1}^{t_2} \lambda(t) dt}}{k!} \quad (1)$$

همچنین برای تحلیل ترافیک کلان‌داده در سطح سوئیچ‌ها و گیت‌وی‌ها، شدت ترافیک شبکه (A) بر حسب ارلانگ (Erlang) محاسبه می‌شود که فرمول ریاضی آن به صورت زیر است:

$$A = \lambda \cdot H \quad (2)$$

که در آن H میانگین زمان پاسخ‌گویی یا مدت زمان نگهداری کانال (Average Holding Time) است. سیستم‌های تحلیل کلان‌داده به اپراتورها اجازه می‌دهند تا با پردازش موازی رکوردهای CDR، پارامترهای λ و H را به صورت محلی، پویا و بلادرنگ برای هر دکل به دست آورند و گلوگاه‌های ظرفیت کانال سیگنالینگ را پیش‌بینی کنند.

۲.۱.۲ داده‌های تجهیزات، زیرساخت و مشتریان

این بخش شامل وضعیت سلامت سرورها، آنتن‌ها (BTS)، توان سیگنال دریافتی و شاخص‌های کلیدی عملکرد نظیر RSRP (توان دریافتی سیگنال مرجع) و SINR (نسبت سیگنال به تداخل به همراه نویز) است. داده‌های عملکردی دکل‌ها اغلب به صورت سری‌های زمانی (Time Series) با فرکانس نمونه‌برداری بالا ذخیره می‌شوند. ذخیره‌سازی این حجم از داده‌های سری زمانی ناهماهنگ، نیازمند پایگاه‌های داده توزیع‌شده و غیررابطه‌ای (NoSQL) مانند Cassandra یا InfluxDB است [۴]. الگوریتم‌های هوش مصنوعی با تحلیل این سری‌های زمانی، ماتریس همبستگی بین رفتار مصرفی مشتریان (User Profile) و میزان افت کیفیت سیگنال را استخراج می‌کنند.

۲.۲ بهینه‌سازی و مدیریت هوشمند شبکه (Network Optimization)

تحلیل کلان‌داده مخابرات، بستری فراهم می‌کند تا فرآیندهای سنتی مدیریت شبکه که مبتنی بر تنظیمات دستی و زمان‌بر بودند، جای خود را به سیستم‌های خودسازمان‌ده (SON - Self-Organizing Networks) بدهند. در ادامه به سرفصل‌های بهینه‌سازی و مدیریت هوشمند شبکه پرداخته و روابط و اصطلاحات مهم آن را توضیح می‌دهیم.

۱.۲.۲ تخصیص پویای منابع (Dynamic Resource Allocation)

یکی از کاربردهای اصلی بیگ دیتا، توزیع بهینه پهنای باند و توان مصرفی فرستنده‌ها بر اساس چگالی ترافیک در هر سلول است. از نظر ریاضی، این مسئله را می‌توان به صورت یک مسئله بهینه‌سازی مقید برای بیشینه‌سازی ظرفیت کانال شانون (Shannon Capacity) فرمول‌بندی کرد.

فرض کنید M کاربر در یک سلول مخابراتی داریم. هدف، تخصیص توان فرستنده (P_i) به کاربر i -ام است به طوری که ظرفیت کل شبکه بیشینه شود:

$$\begin{aligned} \max_{P_i} \sum_{i=1}^M B_i \log_2 \left(1 + \frac{P_i |h_i|^2}{N_0 B_i + I_i} \right) \\ \text{to: subject } \sum_{i=1}^M P_i \leq P_{\max}, \quad P_i \geq 0 \end{aligned} \quad (3)$$

که در آن B_i پهنای باند اختصاص‌یافته، h_i ضریب پاسخ کانال، N_0 چگالی طیفی توان نویز و I_i تداخل ایجاد شده از سلول‌های همجوار است. الگوریتم‌های کلان‌داده با پایش مداوم ماتریس تداخل (I_i) و بهره کانال کاربران، این مسئله غیرخطی را با روش‌هایی مانند مراجع لاگرانژ و الگوریتم واترفیلینگ (Water-Filling) در زمان واقعی حل می‌کنند [۵]. در این حالت، توان به کاربرانی که کانال بهتری دارند بیشتر تخصیص می‌یابد تا نرخ داده کل سلول بهینه شود.

۲.۲.۲ نگهداری پیش‌گیرانه و تشخیص آنومالی (Predictive Maintenance)

در این بخش، هدف پیش‌بینی خرابی سخت‌افزاری یا افت کیفیت فرستنده‌ها قبل از وقوع قطعی کامل است. برای تشخیص الگوهای غیرعادی (آنومالی) در داده‌های سنسورهای چندبعدی یک BTS (مانند دما، ولتاژ منبع تغذیه و نرخ موج ایستاده VSWR)، استفاده از فاصله اقلیدسی به دلیل وجود همبستگی شدید بین پارامترها کارآمد نیست. از این رو، از فاصله ماحالانوبیس (Mahalanobis Distance) استفاده می‌شود که بی‌پلی و مستقل از مقیاس ویژگی‌هاست [۶].

اگر بردار ویژگی‌های فعلی یک تجهیز را با $\mathbf{x}$ ، بردار میانگین وضعیت نرمال تاریخی آن را با $\boldsymbol{\mu}$ و ماتریس کوواریانس داده‌ها را با $\boldsymbol{\Sigma}$ نشان دهیم، فاصله ماحالانوبیس برابر است با:

$$D_M(\mathbf{x}) = \sqrt{(\mathbf{x} - \boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1} (\mathbf{x} - \boldsymbol{\mu})} \quad (4)$$

از آنجا که در محیط‌های کلان‌داده، ماتریس کوواریانس $\boldsymbol{\Sigma}$ به صورت مداوم در حال تغییر است، فریم‌ورک‌های پردازش جریانی (Streaming) مانند Apache Flink این ماتریس را به صورت موازی و لحظه‌ای به‌روزرسانی می‌کنند. هرگاه مقدار $D_M(\mathbf{x})$ از آستانه مشخص (τ) فراتر رود، سیستم یک هشدار خرابی پیش‌رس صادر می‌کند.

۳.۲ پیاده‌سازی کلان‌داده در اپراتورهای پیشرو و داخلی


در دنیای واقعی، گذار از شبکه‌های سنتی به شبکه‌های مبتنی بر کلان‌داده توسط بزرگترین اپراتورهای مخابراتی جهان و همچنین اپراتورهای پیشرو داخلی آغاز شده است. بررسی این پیاده‌سازی‌ها، درک بهتری از کاربرد عملی فریم‌ورک‌های تحلیلی ارائه می‌دهد:

- همراه اول و تحلیل ترافیک داده‌های CDR: در سطح داخلی، اپراتور اول با توسعه پلتفرم‌های بومی کلان‌داده، گام‌های موثری در پردازش روزانه میلیارد‌ها رکورد CDR برداشته است. این زیرساخت با استفاده از تکنیک‌های علم داده به همراه اول اجازه می‌دهد تا با تحلیل الگوهای ترافیکی مشترکین، نقاط پرتراکم شبکه را در رویدادهای خاص شناسایی کرده و توزیع بار را به صورت هوشمند مدیریت کند.

سناریوی بومی: مدیریت توفان سیگنالینگ (Signaling Storm) در عید نوروز یکی از چالش‌برانگیزترین رویدادهای ترافیکی برای اپراتور اول، لحظه تحویل سال نو است که در آن رفتار کاربران به صورت ناگهانی از مصرف دیتا به ارسال پیامک و تماس‌های صوتی تغییر می‌کند. پلتفرم‌های مبتنی بر هوش مصنوعی در همراه اول، با تحلیل داده‌های تاریخی CDR مربوط به سال‌های گذشته، این توفان سیگنالینگ را پیش‌بینی کرده و به صورت خودکار ظرفیت کانال‌های کنترلی (Control Channels) را در گره‌های پرتراکم (مانند اطراف اماکن مذهبی و تفریحی) افزایش می‌دهند. این تخصیص پویای منابع، مانع از افت کیفیت (QoS) و قطعی‌های زنجیره‌ای در هسته شبکه می‌گردد.

- اپراتور AT&T و پلتفرم ECOMP: این اپراتور آمریکایی با معرفی معماری Domain 2.0، بخش عظیمی از تجهیزات سخت‌افزاری خود را به توابع مجازی شبکه (VNF) تبدیل کرد. پلتفرم کلان‌داده این شرکت، روزانه ده‌ها پتابایت داده ترافیکی را پردازش کرده و با استفاده از هوش مصنوعی، منابع شبکه را به صورت خودکار بازتوزیع می‌کند.

- اپراتور Vodafone و تشخیص آنومالی: وودافون با استقرار فریم‌ورک‌های آپاچی اسپارک در هسته شبکه خود، سیستم مانیتورینگ بلادرنگی توسعه داده است که با تحلیل داده‌های سیگنالینگ، ناهنجاری‌ها و قطعی‌های احتمالی آنتن‌ها را پیش از رخ دادن هشدار می‌دهد.



شکل ۲: نمای کلی از معماری مدیریت کلان‌داده و هوش مصنوعی در شبکه‌های مخابراتی مدرن

۳ کاربرد یادگیری ماشین در مدیریت ترافیک و پیش‌بینی قطعی

با گذر از فاز جمع‌آوری و پردازش اولیه در زیرساخت‌های کلان‌داده، لایه هوشمندی شبکه شکل می‌گیرد. در این لایه، الگوریتم‌های یادگیری ماشین (Machine Learning) با تحلیل داده‌های تاریخی و جریانی، قادرند الگوهای پنهان را کشف کرده و رویکرد اپراتور را از حالت انفعالی (Reactive) به تصمیم‌گیری پیش‌گیرانه (Proactive) ارتقا دهند.

به کارگیری این الگوریتم‌ها در لایه مدیریت ترافیک، مزایای فنی و اقتصادی متعددی را برای اپراتورهای مخابراتی به همراه دارد:

- کاهش هزینه‌های عملیاتی (OPEX): سیستم‌های سنتی نیازمند پایش مداوم و تنظیمات دستی پارامترهای شبکه توسط تکنسین‌ها بودند. یادگیری ماشین با خودکارسازی این فرآیند در قالب شبکه‌های خودسازمان‌ده (SON)، هزینه‌های نگهداری را به شدت کاهش می‌دهد.

- مدل‌سازی روابط پیچیده و غیرخطی: داده‌های مخابراتی (نظیر تداخل، توان سیگنال و بار ترافیکی) ماهیتی به شدت غیرخطی و چندبعدی دارند. روش‌های آماری کلاسیک در مواجهه با این حجم از ابعاد داده دچار خطای شدید می‌شوند، در حالی که الگوریتم‌های هوش مصنوعی توانایی بالایی در نگاشت این روابط پیچیده دارند.

- بهبود کیفیت تجربه مشتری (QoE): پیش‌بینی زودهنگام اشباع ظرفیت دکل‌ها و جلوگیری از قطعی، مستقیماً منجر به کاهش نرخ قطع تماس (Call Drop Rate) و پایداری پهنای باند مشترکین در ساعات پیک مصرف می‌گردد.

در ادامه، مراجع ریاضی و ساختار تخصصی پایش الگوهای ترافیکی و پیش‌بینی اختلالات بر مبنای این الگوریتم‌ها مورد بررسی قرار می‌گیرد.

۱.۳ تحلیل الگوهای ترافیکی و پیش‌بینی بار شبکه

پیش‌بینی بار ترافیکی (Traffic Load Forecasting) در هسته خود یک مسئله کلاسیک در تحلیل سری‌های زمانی است. شبکه‌های مخابراتی دارای الگوهای مصرف تناوبی (روزانه، هفتگی و فصلی) هستند که رفتارهای اجتماعی و کاری مشترکین را منعکس می‌کنند. برای پیش‌بینی ترافیک یک سلول در بازه‌های زمانی آینده، در گام نخست از مدل‌های یادگیری نظارت‌شده مانند درختان تصمیم پیشرفته و شبکه‌های بازگشتی کلاسیک استفاده می‌شود.

هدف این الگوریتم‌ها، کمینه‌سازی تابع هزینه (Cost Function) یا خطای پیش‌بینی است. اگر مقدار واقعی ترافیک در یک لحظه مشخص را با y_i و مقدار پیش‌بینی شده توسط مدل را با $\hat{y}_i$ نشان دهیم، الگوریتم به دنبال یافتن پارامترهای بهینه (θ) برای کمینه‌سازی خطای میانگین مربعات (MSE) است:

$$\mathcal{L}(\theta) = \frac{1}{N} \sum_{i=1}^N (y_i - \hat{y}_i(\mathbf{x}_i, \theta))^2 \quad (5)$$

که در آن $\mathbf{x}_i$ بردار ویژگی‌های ترافیکی ورودی (نظیر تعداد کاربران فعال، پهنای باند مصرفی و ساعت شبانه‌روز) در آن سلول مخابراتی است [۷].

با این حال، با تراکم فزاینده سلول‌ها و آنتن‌ها در شبکه‌های نسل جدید (5G)، وضعیت ترافیکی یک دکل مخابراتی منفرد دیگر مستقل از محیط پیرامون خود نیست؛ بلکه ترافیک هر سلول مستقیماً بر دکل‌های مجاور تأثیر گذاشته و از آن‌ها اثر می‌پذیرد (به ویژه در فرآیندهای جابه‌جایی مشترکین یا Handover). رویکردهای کلاسیک سری زمانی مجزا، توانایی مدل‌سازی این وابستگی‌های درهم‌تنیده مکانی-زمانی (Spatio-Temporal) را ندارند.

در استانداردهای نوین علم داده در مخابرات، کل شبکه به عنوان یک گراف جهت‌دار $G = (V, E)$ مدل‌سازی می‌شود که در آن گره‌ها (V) نشان‌دهنده ایستگاه‌های پایه (BTS) و یال‌ها (E) نمایانگر میزان تداخل، همسایگی جغرافیایی یا نرخ جابه‌جایی بین آن‌هاست.

برای پیش‌بینی دقیق و همه‌جانبه بار در این ساختارهای متراکم، رویکردها به سمت معماری‌های گراف-محور نظیر شبکه‌های بازگشتی کانولوشنی انتشار (DCRNN) حرکت کرده‌اند. این الگوریتم، ویژگی‌های مکانی ترافیک را از طریق کانولوشن‌های مبتنی بر فرآیند انتشار تصادفی روی گراف (Diffusion Process) استخراج کرده و سپس آن‌ها را به واحدهای بازگشتی نظیر GRU برای مدل‌سازی ویژگی‌های زمانی منتقل می‌کند. سیگنال ترافیکی پیش‌بینی‌شده برای کل گراف شبکه در گام زمانی $t + 1$ به صورت زیر فرمول‌بندی می‌شود:

$$\mathbf{X}^{(t+1)} = \sigma \left(\sum_{k=0}^{K-1} (\theta_{k,1}(\mathbf{D}_O^{-1}\mathbf{W})^k + \theta_{k,2}(\mathbf{D}_I^{-1}\mathbf{W}^T)^k) \mathbf{X}^{(t)} \right) \quad (6)$$

که در آن $\mathbf{W}$ ماتریس مجاورت گراف شبکه، $\mathbf{D}_O$ و $\mathbf{D}_I$ ماتریس‌های قطری درجه خروجی و ورودی گره‌ها، و θ پارامترهای آموزش‌دیده و بهینه مدل هوش مصنوعی هستند [۸]. این تلفیق هوشمندانه، پایداری پیش‌بینی بار شبکه را در لایه‌های توزیع ترافیک به شدت افزایش می‌دهد.

۲.۳ مدیریت ترافیک در شرایط و رخداد‌های خاص

یکی از چالش‌برانگیزترین سناریوها برای اپراتورهای موبایل، مدیریت منابع شبکه در زمان رخداد‌های خاص (نظیر مسابقات شهرآورد در یک ورزشگاه، لحظه تحویل سال نو یا وقوع بحران‌های طبیعی) است. از دیدگاه تحلیل سیستم‌ها، این رخدادها معادل اعمال یک ورودی پله (Step Input) یا ضربه (Impulse) با دامنه بسیار بالا به شبکه مخابراتی هستند.

در این شرایط، توزیع ترافیک به شدت متمرکز (Spatio-temporally Concentrated) می‌شود. الگوریتم‌های هوش مصنوعی با پایش شیب تغییرات ترافیک، به عنوان یک کنترل‌کننده حلقه بسته عمل می‌کنند. با تشخیص زودهنگام یک پیک ترافیکی، سیستم به صورت خودکار ظرفیت کانال‌های سیگنالینگ دکل‌های مجاور را افزایش داده و در صورت نیاز، کاربران حاشیه سلول بحرانی را به دکل‌های همسایه منتقل (Load Balancing) می‌کند [۹].

۳.۳ شناسایی نقاط مستعد اختلال و پیش‌بینی قطعی

پیش‌بینی قطعی (Outage Prediction) ماهیتاً یک مسئله دسته‌بندی (Classification) در یادگیری ماشین است. بر اساس لاگ‌های خطا و داده‌های سنسورها، مدل باید تشخیص دهد که آیا یک گره مخابراتی در بازه زمانی مشخصی دچار اختلال خواهد شد یا خیر.

در شبکه‌های مدرن، علاوه بر پیش‌بینی اصل وقوع قطعی، نوع خرابی (مثلاً افت توان، تداخل امواج یا خطای نرم‌افزاری) نیز اهمیت دارد. برای این دسته‌بندی چندکلاسه، از توابع فعال‌سازی پیشرفته نظیر بیشینه هموار (Softmax) در لایه خروجی شبکه‌های عصبی یا رگرسیون لجستیک تعمیم‌یافته استفاده می‌شود. احتمال وقوع خرابی نوع k برای دکلی با بردار ویژگی $\mathbf{x}$ به صورت زیر محاسبه می‌گردد:

$$P(y = k|\mathbf{x}) = \frac{e^{\mathbf{w}_k^T \mathbf{x}}}{\sum_{j=1}^K e^{\mathbf{w}_j^T \mathbf{x}}} \quad (7)$$

در این معادله، $\mathbf{w}$ بردارهای وزن آموزش‌دیده مدل هستند. با محاسبه مستمر این احتمالات، سیستم یک لیست اولویت‌بندی‌شده از نقاط مستعد خطر ایجاد کرده و تیم‌های نگهداری و عملیات (O&M) را پیش از بروز بحران به محل اعزام می‌کند [۱۰].

۴.۳ بازتوزیع هوشمند منابع بر اساس تحلیل داده‌ها

پس از پیش‌بینی ترافیک و شناسایی نقاط مستعد اختلال، گام نهایی در یک شبکه خودسازمان‌ده (SON)، اتخاذ تصمیم و اعمال اقدام کنترلی است. این فرآیند شباهت زیادی به یک سیستم کنترل حلقه بسته دارد؛ جایی که کلان‌داده‌ها به عنوان سیگنال فیدبک عمل کرده و الگوریتم‌های هوش مصنوعی، فرامین لازم برای تنظیم پهنای باند یا توان فرستنده‌ها را صادر می‌کنند.

یکی از رویکردهای نوین در این بخش، استفاده از یادگیری تقویتی (Reinforcement Learning) است. در این ساختار، یک عامل هوشمند (Agent) با محیط شبکه در تعامل است و تلاش می‌کند تا با انتخاب بهترین عمل (Action) — مانند تغییر زاویه شیب آنتن (Antenna Tilt) یا تنظیم آستانه Handover — تابع پاداش تجمعی را بیشینه کند.

اگر وضعیت شبکه در زمان t را با s_t و عمل انتخابی را با a_t نشان دهیم، پاداش دریافتی $r(s_t, a_t)$ می‌تواند تابعی از نرخ موفقیت تماس‌ها و کاهش قطعی باشد. هدف، یافتن سیاستی (π) است که مقدار مورد انتظار پاداش‌های آتی را بیشینه کند:

$$V^\pi(s) = \mathbb{E}_\pi \left[\sum_{k=0}^{\infty} \gamma^k r_{t+k+1} \middle| s_t = s \right] \quad (۸)$$

که در آن $\gamma \in [0, 1]$ ضریب تنزیل (Discount Factor) است [۱۱]. این رویکرد به شبکه اجازه می‌دهد تا بدون نیاز به دخالت انسانی، به صورت پیوسته خود را با نوسانات ترافیکی وفق داده و منابع را از سلول‌های خلوت به سمت نقاط بحرانی هدایت کند.

۵.۳ پیاده‌سازی عملی: تشخیص ناهنجاری با تلفیق تجزیه STL و جنگل انزوا

برای اثبات کارآمدی مفاهیم تئوری مطرح شده و پاسخ به چالش‌های عملیاتی مانیتورینگ شبکه، یک شبیه‌سازی نرم‌افزاری بر اساس داده‌های ترافیکی یک‌هفته‌ای (۱۶۸ ساعت) یک ایستگاه پایه (BTS) پیاده‌سازی گردید. ترافیک شبکه‌های مخابراتی ماهیتی به شدت تناوبی (Seasonal) دارد؛ مصرف در طول روز به اوج رسیده و در نیمه‌شب افت می‌کند. اعمال مستقیم الگوریتم‌های تشخیص آنومالی مانند جنگل انزوا (Isolation Forest) روی داده‌های خام سری زمانی، یک خطای متدولوژیک رایج است؛ چرا که مدل، پیک‌های طبیعی روزانه را به دلیل تفاوت در مقدار عددی، به عنوان رفتار غیرعادی تفسیر کرده و نرخ هشدارهای کاذب (False Positives) را به شدت افزایش می‌دهد.

برای غلبه بر این چالش، در این مینی‌پروژه ابتدا داده‌های خام ترافیک با استفاده از الگوریتم پیشرفته STL (Seasonal and Trend decomposition using Loess) تجزیه گردیدند. از نظر ریاضی، این الگوریتم سری زمانی ترافیک ($Y(t)$) را به سه مؤلفه جمع‌پذیر تفکیک می‌کند:

$$Y(t) = T(t) + S(t) + R(t) \quad (۹)$$

که در آن $T(t)$ مؤلفه روند (Trend) جهت پایش تغییرات بلندمدت، $S(t)$ مؤلفه فصلی (Seasonal) با دوره تناوب ۲۴ ساعته برای مدل‌سازی چرخه‌های شبانه‌روز، و $R(t)$ مؤلفه باقیمانده یا تفاضلی (Residue/Remainder) است که نوسانات تصادفی و نویزهای خارج از الگوهای پیش‌بینی‌پذیر را نشان می‌دهد.

پس از حذف اثرات روند و فصلی بودن، الگوریتم یادگیری بدون نظارت Isolation Forest منحصراً بر روی مؤلفه باقیمانده ($R(t)$) آموزش داده شد. از آنجا که نوسانات طبیعی شبانه‌روز در این مؤلفه وجود ندارند، هرگونه رفتار غیرعادی در $R(t)$ نشان‌دهنده یک ناهنجاری یا اختلال واقعی در شبکه است. اگرچه الگوریتم پایه Isolation Forest عملکرد مطلوبی دارد، اما در فضاهای متراکم داده‌ای مخابراتی دچار واریانس بالا می‌شود. برای ارتقای این

ساختار، معماری‌های مقاوم‌تری نظیر LSHiForest (استفاده از Locality-Sensitive Hashing برای کاهش واریانس) و siForest (جهت شناسایی الگوهای ساختاریافته حملات سایبری مبتنی بر مجموعه داده) در سیستم‌های SOC/NOC اپراتورها پیشنهاد می‌گردد. همچنین برای اعتبارسنجی کمی این شبیه‌سازی، از معیارهای دقیق آماری ارزیابی دسته‌بدها (شامل ماتریس درهم‌ریختگی و F1-Score) استفاده شده است.



شکل ۳: تشخیص هوشمند ناهنجاری‌های ترافیکی دکل بر روی مؤلفه باقیمانده (Residue) پس از تجزیه STL

همان‌طور که در شکل ۳ مشاهده می‌شود، مدل هوش مصنوعی موفق شده است با دقت بالایی جهش‌های ناگهانی ترافیک (تجمع غیرمنتظره کاربران در ساعات ۴۰ و ۱۳۵) و افت شدید ترافیک (خرابی یا قطعی سخت‌افزاری در ساعت ۱۰۰) را دقیقاً بر روی مؤلفه باقیمانده ردیابی کرده و با دایره‌های قرمز رنگ علامت‌گذاری کند. این رویکرد ترکیبی، با کاهش چشمگیر هشدارهای کاذب، پایداری سیستم‌های مانیتورینگ مراجع مدیریت شبکه را تضمین می‌کند.

۴ همسویی استراتژیک با چشم‌انداز تحقیق و توسعه همراه اول (MCI R&D)

با حرکت صنعت مخابرات به سمت شبکه‌های نسل پنجم پیشرفته (5.5G) و فراتر از آن، مدیریت ترافیک نیازمند معماری‌های استاندارد و یکپارچه است. معماری پیشنهادی در این گزارش، تطابق کاملی با استراتژی‌های کلان اپراتور اول در راستای گذار از یک شرکت ارتباطی (Telco) به یک شرکت فناوری‌محور (Techco) دارد:

- پردازش لبه موبایل (MEC): ادغام الگوریتم‌های تشخیص قطعی با زیرساخت‌های لبه شبکه همراه اول، تاخیر پردازشی را کاهش داده و امکان پاسخ‌گویی بلادرنگ در کاربردهای حساسی نظیر اینترنت اشیا (IoT) و جاده‌های هوشمند را فراهم می‌سازد.
- استانداردسازی معماری هوش مصنوعی: استقرار این الگوریتم‌ها منطبق بر معماری استاندارد NWDAF (تابع تحلیل داده شبکه در 3GPP) و بهره‌گیری از مفهوم جعبه‌شنی یادگیری ماشین (ML Sandbox - ITU-T Y.3172) تضمین‌کننده پایداری سیستم در محیط عملیاتی است.
- انطباق با شبکه‌های باز (O-RAN): مدل‌های آموزش‌دیده نظیر جنگل انزوا، می‌توانند در قالب برنامه‌های هوشمند (rApp/xApp) روی کنترلرهای هوشمند رادیویی (RIC) مستقر شده و منابع رادیویی را به صورت کاملاً خودمختار بازتوزیع کنند.
- مدیریت شبکه‌های بدون دخالت انسان (Zero-Touch Network and Service Management - ZSM): در این معماری، عامل‌های هوش مصنوعی در تمامی لایه‌های شبکه (از لایه فیزیکی تا لایه کاربرد) توزیع شده و فرآیندهای تخصیص منابع، رفع خطا و بهینه‌سازی ترافیک به صورت انتها-به-انتها (End-to-End) و کاملاً بدون نیاز به دخالت اپراتور انسانی انجام می‌گیرد.
- همزاد دیجیتال (Digital Twin): یکی از انقلابی‌ترین کاربردهای هوش مصنوعی، ایجاد یک نسخه شبیه‌سازی‌شده و کاملاً همگام از کل شبکه فیزیکی در فضای ابری است. این همزاد دیجیتال با دریافت مداوم جریان کلان‌داده‌ها، به اپراتورها اجازه می‌دهد تا پیش از پیاده‌سازی هرگونه تغییر پیکربندی یا بازتوزیع منابع روی شبکه واقعی، نتایج و خطرهای احتمالی آن را در یک محیط مجازی شبیه‌سازی و ارزیابی کنند [۱۲].

۱.۴ شاخص‌های کلیدی عملکرد (KPI) در نگهداری پیش‌گیرانه

اگرچه بهبود کیفیت تجربه مشتری (QoE) و کاهش هزینه‌های عملیاتی دستاوردهای کلان این سیستم‌ها محسوب می‌شوند، اما سنجش دقیق موفقیت مدل‌های هوش مصنوعی در سطح ایستگاه‌های پایه نیازمند ارزیابی متریک‌های مهندسی زیر است:

- میانگین زمان تعمیر (MTTR): هوش مصنوعی با تبدیل رویکرد واکنشی به پیش‌گیرانه، زمان کشف و اعزام تکنسین را به حداقل رسانده و این شاخص را به شدت بهبود می‌بخشد.
- دقت پیش‌بینی (Precision & Recall): بهینه‌سازی این متریک‌ها در مدل‌های طبقه‌بندی، از اعزام‌های غیرضروری و تولید هشدارهای کاذب (False Positives) جلوگیری می‌کند.
- اثربخشی کلی تجهیزات (OEE): ترکیبی از در دسترس بودن (Availability) و عملکرد دکل‌ها است که با کاهش قطعی‌های ناخواسته بهینه‌سازی می‌شود.

۵ جمع‌بندی و نتیجه‌گیری راهبردی

این پروژه با هدف بررسی عمیق و کاربردی تلفیق کلان‌داده (Big Data) و هوش مصنوعی در زیرساخت‌های مخابراتی تدوین گردید. یافته‌های این پژوهش نشان می‌دهد که حجم عظیم داده‌های تولید شده نظیر رکوردهای CDR و لاگ‌های تجهیزات، دیگر یک چالش ذخیره‌سازی نیستند، بلکه یک دارایی استراتژیک برای اپراتورها محسوب می‌شوند. با گذر از معماری‌های سنتی و استقرار چارچوب‌های پردازش توزیع شده، بستر لازم برای بلوغ شبکه‌های مخابراتی فراهم شده است.

از منظر فنی و عملیاتی، استقرار الگوریتم‌های یادگیری ماشین (از جمله شبکه‌های گرافی DCRNN و روش‌های کشف ناهنجاری نظیر جنگل انزوا)، رویکرد اپراتور را از حالت مدیریت واکنشی به فاز مدیریت پیش‌گیرانه (Proactive) ارتقا می‌دهد. شبیه‌سازی‌های انجام شده در این گزارش اثبات نمود که هوش مصنوعی قادر است با تفکیک الگوهای فصلی و روندهای ترافیکی، نقاط مستعد قطعی یا گلوگاه‌های تراکم را پیش از بروز بحران شناسایی نماید. این امر مستقیماً منجر به کاهش زمان تعمیرات (MTTR)، کاهش هزینه‌های عملیاتی (OPEX) و افزایش چشمگیر پایداری کیفیت تجربه مشتری (QoE) در زمان رخدادهای پرتراфик می‌گردد.

در نهایت، از منظر استراتژی کلان سازمانی، پیاده‌سازی این چارچوب‌های هوشمند برای اپراتورهای پیشرو نظیر همراه اول، یک الزام قطعی در مسیر گذار از یک شرکت ارائه‌دهنده خدمات ارتباطی (Telco) به یک غول فناوری محور (Techco) است. توسعه معماری‌های غیرمتمرکز، پردازش لبه موبایل (MEC) و بهره‌گیری از همزادهای دیجیتال، پایه‌های اصلی شبکه‌های خودمختار نسل پنجم و ششم خواهند بود که پایداری، امنیت و چابکی را در اکوسیستم ارتباطات آینده تضمین می‌کنند.

- [1] A. Zahid et al., "Big Data Analytics in Telecommunications: Literature Review and Architecture Recommendations," *IEEE/CAA Journal of Automatica Sinica*, vol. 7, no. 1, pp. 18-38, 2020.
- [2] K. Sultan, H. Ali, and Z. Zhang, "Call Detail Records Driven Anomaly Detection and Traffic Prediction in Mobile Cellular Networks," *IEEE Access*, vol. 6, pp. 41728–41737, 2018.
- [3] B. Hussain, Q. Du, A. Imran, and M. A. Imran, "Artificial Intelligence-Powered Mobile Edge Computing-Based Anomaly Detection in Cellular Networks," *IEEE Transactions on Industrial Informatics*, vol. 16, no. 8, pp. 4986–4996, 2020.
- [4] F. Tramarin, S. Vitturi, and M. Luvisotto, "Industrial Internet of Things: Persistence for Time Series with NoSQL Databases," in *Proc. IEEE Int. Conf. Industrial Informatics (INDIN)*, 2019, pp. 1541–1546. DOI: 10.1109/INDIN41052.2019.8795406
- [5] P. He, L. Zhao, S. Zhou, and Z. Niu, "Water-Filling: A Geometric Approach and Its Application to Solve Generalized Radio Resource Allocation Problems," *IEEE Transactions on Wireless Communications*, vol. 12, no. 7, pp. 3637–3647, 2013.
- [6] B. Hussain, Q. Du, A. Imran, and M. A. Imran, "Artificial Intelligence-Powered Mobile Edge Computing-Based Anomaly Detection in Cellular Networks," *IEEE Transactions on Industrial Informatics*, vol. 16, no. 8, pp. 4986–4996, 2020.
- [7] J. Zhang et al., "Machine Learning for Cellular Traffic Prediction: A Survey," *IEEE Communications Surveys & Tutorials*, vol. 23, no. 1, pp. 144–177, 2021.
- [8] Y. Li et al., "Diffusion Convolutional Recurrent Neural Network: Data-Driven Traffic Forecasting," *International Conference on Learning Representations (ICLR)*, 2018.
- [9] P. V. Klaine, M. A. Imran, O. Onireti, and R. D. Souza, "A Survey of Machine Learning Techniques Applied to Self-Organizing Cellular Networks," *IEEE Communications Surveys & Tutorials*, vol. 19, no. 4, pp. 2392–2431, 2017.
- [10] B. Hussain, Q. Du, A. Imran, and M. A. Imran, "Artificial Intelligence-Powered Mobile Edge Computing-Based Anomaly Detection in Cellular Networks," *IEEE Transactions on Industrial Informatics*, vol. 16, no. 8, pp. 4986–4996, 2020.
- [11] J. A. Hurtado Sánchez, K. Casilimas, and O. M. Caicedo Rendon, "Deep Reinforcement Learning for Resource Management on Network Slicing: A Survey," *Sensors*, vol. 22, no. 8, p. 3031, 2022. DOI: 10.3390/s22083031

- [12] X. Shen et al., “Digital Twin-Empowered AI Routing for 6G Networks,” *IEEE Network*, vol. 38, no. 1, pp. 24-31, 2024.

پیوست آ: کدهای منبع تشخیص ناهنجاری ترافیک شبکه

در راستای حفظ شفافیت علمی و تکرارپذیری (Reproducibility) شبیه‌سازی‌های انجام شده در بخش ۵.۳، اسکریپت پایتون استفاده شده برای تولید داده‌ها، پیش‌پردازش STL و آموزش ابرپارامترهای مدل Isolation Forest در ادامه پیوست شده است:

```
"""
Telecommunication_Network_Traffic_Anomaly_Detection
Using_STL_Decomposition_and_Isolation_Forest_Algorithm

Author: Vahid_Hamzeh
Project: Hamrah_Aval_Academy
"""

import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import matplotlib.gridspec as gridspec
import matplotlib.dates as mdates
from statsmodels.tsa.seasonal import STL
from sklearn.ensemble import IsolationForest
from sklearn.preprocessing import StandardScaler

# 1. Generate Synthetic Data
np.random.seed(42)
N = 168
hours = np.arange(N)

def daily_pattern(h):
    h_mod = h % 24
    morning_peak = 35 * np.exp(-0.5 * ((h_mod - 9) / 2.5) ** 2)
    evening_peak = 50 * np.exp(-0.5 * ((h_mod - 20) / 2.0) ** 2)
    night_base = 10 * np.exp(-0.5 * ((h_mod - 3) / 3.0) ** 2)
    return morning_peak + evening_peak + night_base + 20

seasonal = np.array([daily_pattern(h) for h in hours])
trend = 5 * np.sin(hours * np.pi / N) + 0.02 * hours
noise = np.random.normal(0, 3.5, N)
traffic = seasonal + trend + noise

# Add anomalies
traffic[38:44] += np.array([18, 42, 55, 48, 30, 15])
traffic[133:139] += np.array([12, 35, 45, 38, 22, 10])
traffic[98:103] -= np.array([30, 55, 60, 52, 35])
traffic[98:103] = np.maximum(traffic[98:103], 2)

# 2. DataFrame
timestamps = pd.date_range("2024-03-10 00:00", periods=N, freq="h")
df = pd.DataFrame({"Traffic_Mbps": traffic}, index=timestamps)
```

```

# 3. STL Decomposition
stl = STL(df["Traffic_Mbps"], period=24, robust=True)
result = stl.fit()
df["Trend"], df["Seasonal"], df["Residue"] = result.trend, result.seasonal,
    result.resid

# 4. Anomaly Detection
df["Residue_abs"] = df["Residue"].abs()
df["Residue_lag1"] = df["Residue"].shift(1).fillna(0)
df["Residue_lag2"] = df["Residue"].shift(2).fillna(0)
X = df[["Residue", "Residue_abs", "Residue_lag1", "Residue_lag2"]].values
X_scaled = StandardScaler().fit_transform(X)

iso_forest = IsolationForest(contamination=0.04, random_state=42)
df["Anomaly_Flag"] = iso_forest.fit_predict(X_scaled)
df["Anomaly_Score"] = iso_forest.score_samples(X_scaled)
anomalies = df[df["Anomaly_Flag"] == -1]

# 5. Plotting
plt.rcParams.update({"font.family": "DejaVu_Sans", "figure.facecolor": "#0
    D1117", "axes.facecolor": "#161B22", "text.color": "#C9D1D9", "axes.
    labelcolor": "#C9D1D9", "xtick.color": "#8B949E", "ytick.color": "#8
    B949E"})

fig = plt.figure(figsize=(14, 12))
gs = gridspec.GridSpec(5, 1, hspace=0.4)

# Panel 1: Raw Traffic
ax1 = fig.add_subplot(gs[0])
ax1.plot(df.index, df["Traffic_Mbps"], color="#58A6FF", label="Traffic")
ax1.scatter(anomalies.index, anomalies["Traffic_Mbps"], color="#FF7B72",
    label="Anomaly")
ax1.set_title("Raw_Network_Traffic_&_Detected_Anomalies")
ax1.legend()

# Panel 2: Trend
ax2 = fig.add_subplot(gs[1])
ax2.plot(df.index, df["Trend"], color="#3FB950")
ax2.set_title("Trend_Component")

# Panel 3: Seasonal
ax3 = fig.add_subplot(gs[2])
ax3.plot(df.index, df["Seasonal"], color="#D2A8FF")
ax3.set_title("Seasonal_Component")

# Panel 4: Residue
ax4 = fig.add_subplot(gs[3])
ax4.plot(df.index, df["Residue"], color="#79C0FF")
ax4.scatter(anomalies.index, anomalies["Residue"], color="#FF7B72")
ax4.set_title("Residue_Component")

```



```
# Panel 5: Anomaly Score
ax5 = fig.add_subplot(gs[4])
ax5.plot(df.index, df["Anomaly_Score"], color="#56D364")
ax5.set_title("Anomaly_Score_(Lower_=More_Anomalous)")

plt.tight_layout()
plt.savefig("anomaly_detection_plot.png", dpi=150)
plt.show()
```